



機械学習 Machine Learning

グラフィカルモデル Graphical Models


福島 誠 Makoto Fukushima

情報科学部
School of Informatics and Data Science

グラフィカルモデル Graphical models

有向グラフ Directed graphs

グラフィカルモデルによって確率分布の構造を図示することができる。
Graphical models allows structured probability distributions to be expressed in graphical form.



ノード : 確率変数

Nodes: random variables

リンク : 変数間の確率的な関係


Links: probabilistic relationships between variables

グラフのリンクが矢印による特定の向きをもつ有向グラフィカルモデルに焦点をあてる。

We will focus on directed graphical models in which the links of the graphs have a particular direction indicated by arrows.

グラフィカルモデル Graphical models

分解 Factorization



確率の乗法定理を適用

Application of the product rule of probability

$$p(a, b, c) = p(c|a, b)p(a, b) = p(c|a, b)p(b|a)p(a)$$

ノード a はノード b の親.

Node a is the parent of node b .

ノード b はノード a の子.

Node b is the child of node a .

K 個の変数の同時分布に対しては,

For the joint distribution over K variables,

$$p(x_1, \dots, x_K) = p(x_K|x_1, \dots, x_{K-1}) \dots p(x_2|x_1)p(x_1)$$


グラフィカルモデル Graphical models

分解 Factorization

グラフが全結合していないケース

In a case where the graph is not fully connected

$$\begin{aligned} p(x_1, \dots, x_7) &= p(x_1)p(x_2)p(x_3)p(x_4|x_1, x_2, x_3) \\ &\quad p(x_5|x_1, x_3)p(x_6|x_4)p(x_7|x_4, x_5) \end{aligned}$$



一般的な分解

General factorization

$$p(x_1, \dots, x_K) = \prod_{k=1}^K p(x_k | \text{pa}(k))$$

$\text{pa}(k)$: x_k の親の集合 The set of parents of x_k

ここで考えているグラフは有向閉路をもたないという制約を満たす（有向非循環グラフ）。

In the graph we are considering, there are no closed path (directed acyclic graph).

グラフィカルモデル Graphical models


離散変数 Discrete variables

一般的な同時分布

General joint distribution

$K^2 - 1$ 個のパラメータ

$K^2 - 1$ parameters




$$p(\mathbf{x}_1, \mathbf{x}_2 | \boldsymbol{\mu}) = \prod_{k=1}^K \prod_{l=1}^K \mu_{kl}^{x_{1k} x_{2l}}$$

独立な同時分布

Independent joint distribution

$2(K-1)$ 個のパラメータ

$2(K-1)$ parameters



$$\hat{p}(\mathbf{x}_1, \mathbf{x}_2 | \boldsymbol{\mu}) = \prod_{k=1}^K \mu_{1k}^{x_{1k}} \prod_{l=1}^K \mu_{2l}^{x_{2l}}$$

グラフィカルモデル Graphical models

離散変数 Discrete variables

一般的な同時分布（変数が M 個ある場合） $K^M - 1$ 個のパラメータ

General joint distribution over M variables $K^M - 1$ parameters


（グラフが全結合している場合 If the graph is fully connected）

独立な同時分布（変数が M 個ある場合） $M(K - 1)$ 個のパラメータ

Independent joint distribution over M variables $M(K - 1)$ parameters

以下の M 個のノードの連鎖の場合

The following chain of M nodes



$K - 1 + (M - 1)K(K - 1)$ 個のパラメータ

$K - 1 + (M - 1)K(K - 1)$ parameters

グラフィカルモデル Graphical models

離散変数 Discrete variables

一般的な同時分布（変数が M 個ある場合） $K^M - 1$ 個のパラメータ

General joint distribution over M variables $K^M - 1$ parameters


（グラフが全結合している場合 If the graph is fully connected）

独立な同時分布（変数が M 個ある場合） $M(K - 1)$ 個のパラメータ

Independent joint distribution over M variables $M(K - 1)$ parameters

以下の M 個のノードの連鎖の場合

The following chain of M nodes




$K - 1 + K(K - 1) = K^2 - 1$ 個のパラメータ

$K - 1 + K(K - 1) = K^2 - 1$ parameters

グラフィカルモデル Graphical models

離散変数 Discrete variables



x_1, \dots, x_M が K 個の状態を取り得る離散変数のとき,
 $p(y = 1 | x_1, \dots, x_M)$ は一般的に $O(K^M)$ 個のパラメータをもつ.

If x_1, \dots, x_M are discrete K -state variables,
 $p(y = 1 | x_1, \dots, x_M)$ in general has $O(K^M)$ parameters.

以下でパラメタライズされた形式の場合は,
The parametrized form

$$p(y = 1 | x_1, \dots, x_M) = \sigma \left(w_0 + \sum_{i=1}^M w_i x_i \right) = \sigma(\mathbf{w}^T \mathbf{x})$$

$M + 1$ 個のパラメータしか必要としない.
requires only $M + 1$ parameters.

グラフィカルモデル Graphical models

ガウス変数 Gaussian variables

$$p(x_i | \text{pa}_i) = \mathcal{N} \left(x_i \left| \sum_{j \in \text{pa}_i} w_{ij} x_j + b_i, v_i \right. \right)$$

各ノードはガウス変数であり,
その平均は親ノードの線形関数で表される.
Each node is Gaussian and the mean
is a linear function of the parents.

同時分布の対数 The log of the joint distribution

$$\ln p(\mathbf{x}) = \sum_{i=1}^D \ln p(x_i | \text{pa}(i)) = - \sum_{i=1}^D \frac{1}{2v_i} \left(x_i - \sum_{j \in \text{pa}(i)} w_{ij} x_j - b_i \right)^2 + \text{const}$$

平均と共分散 Mean and covariance

$$\mathbb{E}[x_i] = \sum_{j \in \text{pa}(i)} w_{ij} \mathbb{E}[x_j] + b_i \quad \text{cov}[x_i, x_j] = \sum_{k \in \text{pa}(j)} w_{jk} \text{cov}[x_i, x_k] + I_{ij} v_j$$

グラフィカルモデル Graphical models

ガウス変数 Gaussian variables

$$p(x_i | \text{pa}_i) = \mathcal{N} \left(x_i \left| \sum_{j \in \text{pa}_i} w_{ij} x_j + b_i, v_i \right. \right)$$


各ノードはガウス変数であり,
その平均は親ノードの線形関数で表される。
Each node is Gaussian and the mean
is a linear function of the parents.

平均と共分散 Mean and covariance

$$\mathbb{E}[x_i] = \sum_{j \in \text{pa}(i)} w_{ij} \mathbb{E}[x_j] + b_i \quad \text{cov}[x_i, x_j] = \sum_{k \in \text{pa}(j)} w_{jk} \text{cov}[x_i, x_k] + I_{ij} v_j$$

例 Example

$$\mu = (b_1, b_2 + w_{21}b_1, b_3 + w_{32}b_2 + w_{32}w_{21}b_1)^T$$



$$\Sigma = \begin{pmatrix} v_1 & w_{21}v_1 & w_{32}w_{21}v_1 \\ w_{21}v_1 & v_2 + w_{21}^2v_1 & w_{32}(v_2 + w_{21}^2v_1) \\ w_{32}w_{21}v_1 & w_{32}(v_2 + w_{21}^2v_1) & v_3 + w_{32}^2(v_2 + w_{21}^2v_1) \end{pmatrix}$$

グラフィカルモデル Graphical models

ガウス変数 Gaussian variables

$$p(x_i | \text{pa}_i) = \mathcal{N} \left(x_i \left| \sum_{j \in \text{pa}_i} w_{ij} x_j + b_i, v_i \right. \right)$$

各ノードはガウス変数であり,
その平均は親ノードの線形関数で表される.
Each node is Gaussian and the mean
is a linear function of the parents.

多変量ガウス変数に対しては,
For multivariate Gaussian variables,

$$p(\mathbf{x}_i | \text{pa}_i) = \mathcal{N} \left(\mathbf{x}_i \left| \sum_{j \in \text{pa}_i} \mathbf{W}_{ij} \mathbf{x}_j + \mathbf{b}_i, \mathbf{\Sigma}_i \right. \right)$$

グラフィカルモデル Graphical models

二値分類器 Binary classifier


学習パラメータに対するガウス事前分布付き二値分類モデル
Two-class classifier model with Gaussian prior over the learnable parameters

$$p(\mathbf{t}, \mathbf{w} | \mathbf{X}, \lambda) = p(\mathbf{w} | \lambda) \prod_{n=1}^N p(t_n | \mathbf{w}, \mathbf{x}_n)$$


ただし where

$$p(\mathbf{w} | \lambda) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \lambda \mathbf{I})$$

$$p(t | \mathbf{x}, \mathbf{w}) = y(\mathbf{x}, \mathbf{w})^t \{1 - y(\mathbf{x}, \mathbf{w})\}^{(1-t)}$$



または or



プレート Plate

グラフィカルモデル Graphical models

パラメータと観測 Parameters and observations

学習パラメータに対するガウス事前分布付き二値分類モデル
Two-class classifier model with Gaussian prior over the learnable parameters


$$p(\mathbf{t}, \mathbf{w} | \mathbf{X}, \lambda) = p(\mathbf{w} | \lambda) \prod_{n=1}^N p(t_n | \mathbf{w}, \mathbf{x}_n)$$

ただし where

$$p(\mathbf{w} | \lambda) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \lambda \mathbf{I})$$

$$p(t | \mathbf{x}, \mathbf{w}) = y(\mathbf{x}, \mathbf{w})^t \{1 - y(\mathbf{x}, \mathbf{w})\}^{(1-t)}$$

決定的パラメータが陽に描かれた場合
The deterministic parameters are shown explicitly.



グラフィカルモデル Graphical models

パラメータと観測 Parameters and observations

学習パラメータに対するガウス事前分布付き二値分類モデル
Two-class classifier model with Gaussian prior over the learnable parameters


$$p(\mathbf{t}, \mathbf{w} | \mathbf{X}, \lambda) = p(\mathbf{w} | \lambda) \prod_{n=1}^N p(t_n | \mathbf{w}, \mathbf{x}_n)$$

ただし where

$$p(\mathbf{w} | \lambda) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \lambda \mathbf{I})$$

$$p(t | \mathbf{x}, \mathbf{w}) = y(\mathbf{x}, \mathbf{w})^t \{1 - y(\mathbf{x}, \mathbf{w})\}^{(1-t)}$$

$\{t_n\}$ が観測されている場合
When $\{t_n\}$ are observed,



グラフィカルモデル Graphical models

パラメータと観測 Parameters and observations

学習パラメータに対するガウス事前分布付き二値分類モデル
Two-class classifier model with Gaussian prior over the learnable parameters

$$p(\mathbf{t}, \mathbf{w} | \mathbf{X}, \lambda) = p(\mathbf{w} | \lambda) \prod_{n=1}^N p(t_n | \mathbf{w}, \mathbf{x}_n)$$

$\{t_n\}$ が観測されている場合
When $\{t_n\}$ are observed,

ただし where


$$p(\mathbf{w} | \lambda) = \mathcal{N}(\mathbf{w} | \mathbf{0}, \lambda \mathbf{I})$$

$$p(t | \mathbf{x}, \mathbf{w}) = y(\mathbf{x}, \mathbf{w})^t \{1 - y(\mathbf{x}, \mathbf{w})\}^{(1-t)}$$

新たな入力 \hat{x} と対応する \hat{t} を含む分布

Distribution that contains a new input \hat{x} and its corresponding \hat{t}

$$p(\hat{t}, \mathbf{t}, \mathbf{w} | \hat{x}, \mathbf{X}, \lambda) = p(\mathbf{w} | \lambda) p(\hat{t} | \mathbf{w}, \hat{x}) \prod_{n=1}^N p(t_n | \mathbf{w}, \mathbf{x}_n)$$



グラフィカルモデル Graphical models

ベイズの定理 Bayes' theorem



(a)



(b)



(c)

(a) $p(x, y) = p(x)p(y|x)$

(b) y を観測したとする.
Suppose we observe y .

(c)
$$p(x|y) = \frac{p(y|x)p(x)}{p(y)}$$
$$p(y) = \sum_{x'} p(y|x')p(x')$$

条件付き独立性 Conditional independence

c が与えられたとき, a が b に対して独立.

a is independent of b given c .

$$p(a|b, c) = p(a|c)$$

別の表現では Equivalently,

$$\begin{aligned} p(a, b|c) &= p(a|b, c)p(b|c) \\ &= p(a|c)p(b|c) \end{aligned}$$


表記法 Notation

$$a \perp\!\!\!\perp b \mid c$$

条件付き独立性 Conditional independence

3つのグラフの例 Three example graphs


例1 Example 1: tail-to-tail



$$p(a, b, c) = p(a|c)p(b|c)p(c)$$

$$p(a, b) = \sum_c p(a|c)p(b|c)p(c)$$

$$a \not\perp b \mid \emptyset$$




$$\begin{aligned} p(a, b|c) &= \frac{p(a, b, c)}{p(c)} \\ &= p(a|c)p(b|c) \end{aligned}$$

$$a \perp b \mid c$$

条件付き独立性 Conditional independence

3つのグラフの例 Three example graphs


例2 Example 2: head-to-tail



$$p(a, b, c) = p(a)p(c|a)p(b|c)$$

$$a \not\perp\!\!\!\perp b \mid \emptyset$$

$$p(a, b) = p(a) \sum_c p(c|a)p(b|c) = p(a)p(b|a)$$



$$p(a, b|c) = \frac{p(a, b, c)}{p(c)}$$

$$= \frac{p(a)p(c|a)p(b|c)}{p(c)}$$


$$= p(a|c)p(b|c)$$

$$a \perp\!\!\!\perp b \mid c$$

条件付き独立性 Conditional independence

3つのグラフの例 Three example graphs


例3 Example 3: head-to-head



$$p(a, b, c) = p(a)p(b)p(c|a, b)$$

$$p(a, b) = p(a)p(b)$$

$$a \perp\!\!\!\perp b \mid \emptyset$$



$$\begin{aligned} p(a, b|c) &= \frac{p(a, b, c)}{p(c)} \\ &= \frac{p(a)p(b)p(c|a, b)}{p(c)} \end{aligned}$$

$$a \not\perp\!\!\!\perp b \mid c$$

例1, 2と反対の結果. This is the opposite of Examples 1 and 2.

条件付き独立性 Conditional independence

「弁明」 Explaining away

$$p(G = 1|B = 1, F = 1) = 0.8$$

$$p(G = 1|B = 1, F = 0) = 0.2$$


$$p(G = 1|B = 0, F = 1) = 0.2$$

$$p(G = 1|B = 0, F = 0) = 0.1$$

$$p(B = 1) = 0.9 \quad p(B = 0) = 0.1$$

$$p(F = 1) = 0.9 \quad p(F = 0) = 0.1$$

燃料切れ？ Am I out of fuel?



B: バッテリー Battery

F: 燃料タンク Fuel tank

G: 電動燃料系の読み値
Fuel gauge reading

条件付き独立性 Conditional independence

「弁明」 Explaining away

$$p(G = 1|B = 1, F = 1) = 0.8$$

$$p(G = 1|B = 1, F = 0) = 0.2$$

$$p(G = 1|B = 0, F = 1) = 0.2$$

$$p(G = 1|B = 0, F = 0) = 0.1$$

$$p(B = 1) = 0.9 \quad p(B = 0) = 0.1$$


$$p(F = 1) = 0.9 \quad p(F = 0) = 0.1$$

$G = 0$ を観測することで燃料タンクが空である確率が上昇する。

The probability of an empty fuel tank is increased by observing $G = 0$.

$$\begin{aligned} p(F = 0|G = 0) &= \frac{p(G = 0|F = 0)p(F = 0)}{p(G = 0)} \\ &\simeq 0.257 \end{aligned}$$

燃料切れ？ Am I out of fuel?



B : バッテリー Battery

F : 燃料タンク Fuel tank

G : 電動燃料系の読み値
Fuel gauge reading

$$\begin{aligned} p(G = 0|F = 0) &= \sum_{B \in \{0,1\}} p(G = 0|B, F = 0)p(B) = 0.81 \\ p(G = 0) &= \sum_{B \in \{0,1\}} \sum_{F \in \{0,1\}} p(G = 0|B, F)p(B)p(F) = 0.315 \end{aligned}$$

条件付き独立性 Conditional independence

「弁明」 Explaining away

$$p(G = 1|B = 1, F = 1) = 0.8$$

$$p(G = 1|B = 1, F = 0) = 0.2$$

$$p(G = 1|B = 0, F = 1) = 0.2$$

$$p(G = 1|B = 0, F = 0) = 0.1$$

$$p(B = 1) = 0.9 \quad p(B = 0) = 0.1$$


$$p(F = 1) = 0.9 \quad p(F = 0) = 0.1$$

$B = 0$ を観測することで燃料タンクが空である確率が減少する。

The probability of an empty fuel tank is reduced by observing $B = 0$.

$$\begin{aligned} p(F = 0|G = 0, B = 0) &= \frac{p(G = 0|B = 0, F = 0)p(F = 0)}{\sum_{F \in \{0,1\}} p(G = 0|B = 0, F)p(F)} \\ &\simeq 0.111 \end{aligned}$$

燃料切れ？ Am I out of fuel?



B : バッテリー Battery

F : 燃料タンク Fuel tank

G : 電動燃料系の読み値
Fuel gauge reading

条件付き独立性 Conditional independence

有向分離 (D分離) D-separation

有向グラフ内の A , B および C を互いに重複しないノード集合とする.

A , B , and C are non-intersecting subsets of nodes in a directed graph.

A から B への経路は, 以下のいずれかを満たすノードを含むとき, 遮断されているという.

A path from A to B is blocked if it contains a node such that either

- 集合 C に含まれるノードであって, 経路に含まれる矢印がそこでhead-to-tailあるいはtail-to-tailである.
the arrows on the path meet either head-to-tail or tail-to-tail at the node, and the node is in the set C ,
または or
- 経路に含まれる矢印がそのノードでhead-to-headであり, 自身あるいはそのすべての子孫のいずれもが集合 C に含まれない.
the arrows meet head-to-head at the node, and neither the node, nor any of its descendants, are in the set C .

A から B へのすべての経路が遮断されているとき, A は C によって B から有向分離されているという.


If all paths from A to B are blocked, A is said to be d-separated from B by C .

A が C によって B から有向分離されていれば, グラフの全変数上の同時分布は $A \perp\!\!\!\perp B \mid C$ を満たす.


If A is d-separated from B by C , the joint distribution over all variables in the graph satisfies $A \perp\!\!\!\perp B \mid C$.

条件付き独立性 Conditional independence

有向分離 (D分離) D-separation




$$a \not\perp b \mid c$$



$$a \perp b \mid f$$

条件付き独立性 Conditional independence

有向分離 (D分離) D-separation



$\{t_1, \dots, t_N\}$: i.i.d.データ i.i.d. data

ノード \hat{t} から t_n のうちの任意のノードへの経路に関してノード w はtail-to-tailである.


The node for w is tail-to-tail with respect to the path from \hat{t} to any one of the nodes t_n .

$$\Rightarrow \hat{t} \perp\!\!\!\perp t_n \mid w$$

条件付き独立性 Conditional independence

ナীবベイズ Naive Bayes

ナীবベイズモデル Naive Bayes model



$$p(\mathbf{x}|\mathcal{C}_k) = \prod_{l=1}^L p(\mathbf{x}^{(l)}|\mathcal{C}_k)$$

$$\mathbf{x} = (\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(L)})$$


\mathcal{C}_k を観測すると, $\mathbf{x}^{(i)}$ と $\mathbf{x}^{(j)}$ ($j \neq i$) との間の経路が遮断される.

An observation of \mathcal{C}_k would block the path between $\mathbf{x}^{(i)}$ and $\mathbf{x}^{(j)}$ for $j \neq i$.

条件付き独立性 Conditional independence

ナীবベイズ Naive Bayes

ナীবベイズモデル Naive Bayes model



$$p(\mathbf{x}|\mathcal{C}_k) = \prod_{l=1}^L p(\mathbf{x}^{(l)}|\mathcal{C}_k)$$

$$\mathbf{x} = (\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(L)})$$

ベクトル \mathbf{x} がクラス \mathcal{C}_k に所属する確率


The probability that a vector \mathbf{x} belongs to class \mathcal{C}_k

$$p(\mathcal{C}_k|\mathbf{x}) = \frac{p(\mathbf{x}|\mathcal{C}_k)p(\mathcal{C}_k)}{p(\mathbf{x})} \quad \text{ただし where} \quad p(\mathbf{x}) = \sum_{k=1}^K p(\mathbf{x}|\mathcal{C}_k)p(\mathcal{C}_k)$$

条件付き独立性 Conditional independence


ナীবベイズ Naive Bayes

Factorized 分解されている



$$p(\mathbf{x}|\mathcal{C}_k) = p(x_1|\mathcal{C}_k)p(x_2|\mathcal{C}_k)$$

Not factorized 分解されていない




$$p(\mathbf{x}) = \sum_{k=1}^K p(\mathbf{x}|\mathcal{C}_k)p(\mathcal{C}_k)$$

$$\mathbf{x} = (x_1, x_2)$$

条件付き独立性 Conditional independence

生成モデル Generative models




物体の像が生成される過程を表現する
グラフィカルモデル

A graphical model representing
the process by which images of
objects are created

条件付き独立性 Conditional independence

マルコフブランケット Markov blanket

マルコフブランケットに含まれるノード
Nodes included in the Markov blanket




$$\begin{aligned} p(\mathbf{x}_i | \mathbf{x}_{\{j \neq i\}}) &= \frac{p(\mathbf{x}_1, \dots, \mathbf{x}_M)}{\int p(\mathbf{x}_1, \dots, \mathbf{x}_M) d\mathbf{x}_i} \\ &= \frac{\prod_k p(\mathbf{x}_k | \text{pa}_k)}{\int \prod_k p(\mathbf{x}_k | \text{pa}_k) d\mathbf{x}_i} \end{aligned}$$

\mathbf{x}_i に依存しない因子は分子と分母とで
キャンセルされる.

Factors independent of \mathbf{x}_i cancel
between numerator and denominator.

条件付き独立性 Conditional independence

フィルタとしてのグラフ Graph as filters



分解特性 Factorization property

$$p(x_1, \dots, x_K) = \prod_{k=1}^K p(x_k | \text{pa}(k))$$


系列モデル Sequence models

系列データ Sequential data

例：マイクからのオーディオ信号, ある地点における日々の雨量観測値
Examples: audio signals from a microphone,
daily rain fall measurements at a particular location


以下は, 一般性を完全に保っているときの表現
The following expression has complete generality.

$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = p(\mathbf{x}_1) \prod_{n=2}^N p(\mathbf{x}_n | \mathbf{x}_1, \dots, \mathbf{x}_{n-1})$$



系列モデル Sequence models


$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = \prod_{n=1}^N p(\mathbf{x}_n)$$



順序情報を無視

Ignore the ordering information


$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = p(\mathbf{x}_1) \prod_{n=2}^N p(\mathbf{x}_n | \mathbf{x}_{n-1})$$



一次マルコフ連鎖

First-order Markov chain

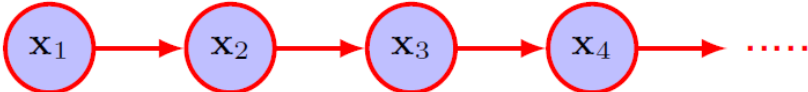
$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = p(\mathbf{x}_1)p(\mathbf{x}_2 | \mathbf{x}_1) \prod_{n=3}^N p(\mathbf{x}_n | \mathbf{x}_{n-1}, \mathbf{x}_{n-2})$$



二次マルコフ連鎖

Second-order Markov chain

系列モデル Sequence models

$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = p(\mathbf{x}_1) \prod_{n=2}^N p(\mathbf{x}_n | \mathbf{x}_{n-1})$$


```
graph LR; x1((x1)) --> x2((x2)); x2 --> x3((x3)); x3 --> x4((x4)); x4 --> dots[.....];
```

一次マルコフ連鎖
First-order Markov chain

有向分離を用いると, Using d-separation,

$$p(\mathbf{x}_n | \mathbf{x}_1, \dots, \mathbf{x}_{n-1}) = p(\mathbf{x}_n | \mathbf{x}_{n-1})$$

観測変数が K 個の状態をもつ離散変数であるとき,

If the observed variables are discrete variables having K states,

パラメータ数 The number of parameters: $K(K - 1)$

M 次マルコフ連鎖では

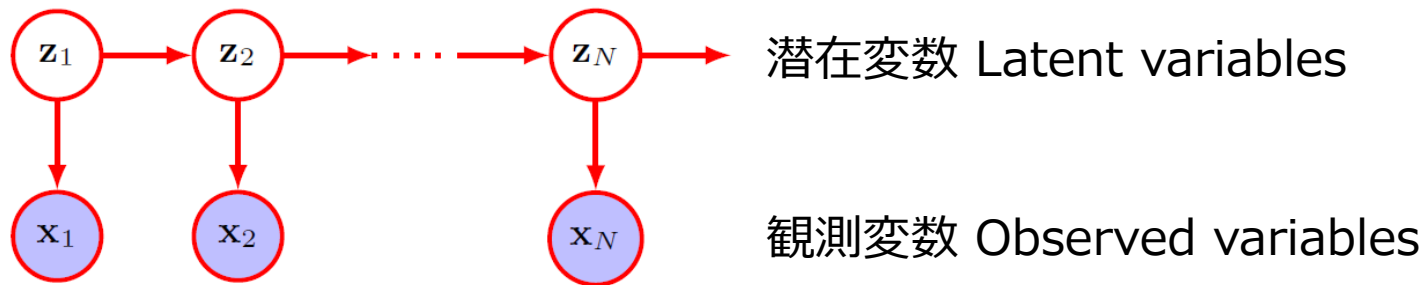
$$K^M(K - 1)$$

In an M -th order Markov chain,

系列モデル Sequence models

隠れ変数 Hidden variables

状態空間モデル State-space model



$\Rightarrow z_{n+1} \perp\!\!\!\perp z_{n-1} \mid z_n$ \mathbf{x}_{n+1} は過去のすべての観測変数に依存する.
 \mathbf{x}_{n+1} depends on all previous observed variables.

上のモデルの同時分布 The joint distribution of the above model

$$p(\mathbf{x}_1, \dots, \mathbf{x}_N, \mathbf{z}_1, \dots, \mathbf{z}_N) = p(\mathbf{z}_1) \left[\prod_{n=2}^N p(\mathbf{z}_n | \mathbf{z}_{n-1}) \right] \prod_{n=1}^N p(\mathbf{x}_n | \mathbf{z}_n)$$



提出課題 IV : グラフィカルモデル Assignment IV: Graphical Models

提出期限 : **11月12日 (火曜日) 23:59:00** [日本標準時]

Submission deadline: **November 12 (Tuesday) 23:59:00** [Japan Standard Time]

提出課題は「一般」チャンネルの「ファイル」にアップロードされます。
同チャンネルに出現する通知のリンク先から解答を送信（提出）してください。
Assignments will be uploaded to "File" in the "General" channel. Send
(submit) your answers via the link that will appear in the same channel.

- 全6回の課題への解答をもとに成績評価を行います。
Your grades will be based on your answers to all six assignments.
- 解答送信後の解答再送信はできません。
Once submitted, answers cannot be resubmitted.
- 提出期限は一切延長しません。
The submission deadline will never be extended.